

Anteproyecto TFM FASE 1

Resumen Ejecutivo

Este proyecto aborda el desarrollo de una plataforma de mantenimiento predictivo para motores de aviación, utilizando el dataset de simulación de degradación de la NASA. El objetivo es construir y validar un modelo de inteligencia artificial, basado en redes neuronales recurrentes (LSTM), capaz de predecir con precisión la **Vida Útil Restante (RUL)** de los motores de turbofán. El sistema se diseñará siguiendo un pipeline MLOps completo, utilizando Apache Spark para el procesamiento de datos, MLflow para la gestión del ciclo de vida del modelo y una API RESTful para su despliegue. Un componente crítico del proyecto es la implementación de técnicas de **IA Explicable (XAI)** para garantizar la interpretabilidad y la confianza en las predicciones. La solución final se materializará en un dashboard interactivo que permitirá a los ingenieros de mantenimiento monitorizar la salud de la flota, optimizar la planificación de las revisiones y aumentar tanto la seguridad operacional como la eficiencia económica de las aerolíneas.

Formulación del Problema

La industria de la aviación se enfrenta a un desafío constante para garantizar la máxima seguridad y disponibilidad de su flota mientras optimiza los costes operativos. El mantenimiento de los motores, uno de los componentes más críticos y costosos, se basa tradicionalmente en dos enfoques subóptimos:

1. **Mantenimiento Reactivo:** Se repara un componente únicamente cuando falla, lo que provoca tiempos de inactividad no planificados (AOG - Aircraft on Ground), cancelaciones de vuelos y costes de reparación de emergencia muy elevados.
2. **Mantenimiento Preventivo:** Se revisan o reemplazan componentes en intervalos fijos (ej. cada X ciclos de vuelo), independientemente de su estado real. Este enfoque, aunque seguro, es ineficiente, ya que a menudo se desechan piezas que todavía tienen una vida útil considerable.

El problema central es la **falta de un método fiable para anticipar los fallos**, lo que impide una gestión proactiva y basada en datos del mantenimiento.

Contexto Sectorial

El sector aeronáutico es una industria de miles de millones de euros donde la eficiencia, la fiabilidad y la seguridad son primordiales. La gestión de la salud de los sistemas (*Systems Health Management*) es un área de investigación muy activa que busca minimizar los costes de mantenimiento no programado y maximizar el uso de los equipos. La predicción de la vida útil restante (RUL) es el núcleo de esta disciplina. Sin embargo, el progreso en este campo se ha visto obstaculizado por la escasez de datos públicos de sistemas que operan hasta el fallo, ya que las empresas que disponen de ellos los protegen por razones competitivas. Este proyecto se enmarca en la respuesta a este desafío, utilizando un

dataset de simulación de alta fidelidad creado por la NASA precisamente para fomentar el desarrollo de algoritmos de pronóstico avanzados.

Usuarios y Partes Interesadas

- **Usuarios Principales:**
 - **Ingenieros de Mantenimiento y Planificadores:** Utilizarán el dashboard para monitorizar la salud de la flota, recibir alertas de RUL crítico y planificar las órdenes de trabajo de forma proactiva.
 - **Analistas de Fiabilidad:** Usarán el sistema para entender mejor los patrones de degradación de los motores y mejorar los modelos de fiabilidad a largo plazo.
- **Partes Interesadas (Stakeholders):**
 - **Jefes de Operaciones de Aerolíneas:** Su interés es maximizar la disponibilidad de la flota y la puntualidad de los vuelos.
 - **Directores Financieros (CFO):** Buscan la reducción de los costes operativos y de inventario de piezas de repuesto.
 - **Fabricantes de Motores:** Pueden usar los datos para mejorar el diseño de futuras generaciones de motores.
 - **Autoridades de Aviación Civil:** Su interés es el incremento de la seguridad operacional en toda la industria.

Riesgos

- **Riesgo Técnico:** La alta complejidad del modelado de series temporales con LSTM puede requerir un tiempo de entrenamiento y ajuste de hiperparámetros superior al planificado.
- **Riesgo de Datos:** Aunque el dataset es de alta calidad, es una simulación. El modelo podría no generalizar perfectamente a datos de motores reales debido a modos de fallo no contemplados en la simulación. Esta limitación deberá ser claramente documentada.
- **Riesgo de Interpretación (XAI):** Las explicaciones generadas por SHAP pueden ser complejas. Existe el riesgo de que los usuarios finales no las comprendan correctamente, lo que podría llevar a una falta de confianza en el sistema.
- **Riesgo de Gestión de Proyecto:** Al ser un equipo de tres personas, la dependencia en un solo miembro para una parte crítica del pipeline (ej. el procesamiento de datos con Spark) puede crear cuellos de botella si esa persona se retrasa.

Valor de Negocio

El desarrollo de un sistema de mantenimiento predictivo fiable genera un valor de negocio tangible y multifacético:

1. **Reducción de Costes Operativos:** Minimiza los gastos asociados a mantenimientos no programados y optimiza el inventario de repuestos, comprando solo las piezas necesarias cuando se necesitan.

2. **Aumento de Ingresos:** Incrementa la disponibilidad y el tiempo de vuelo de las aeronaves, lo que se traduce directamente en una mayor capacidad para generar ingresos.
3. **Mejora de la Seguridad:** La anticipación de fallos en componentes críticos representa un avance significativo en la seguridad operacional.
4. **Ventaja Competitiva:** Una aerolínea con una gestión de mantenimiento más eficiente puede ofrecer precios más competitivos y un servicio más fiable, mejorando su posición en el mercado.

KPIs de Éxito

- **KPI de Modelo (Precisión):**
 - Alcanzar un **Error Cuadrático Medio (RMSE)** en la predicción del RUL inferior a 15 ciclos en el dataset de prueba **FD001**.
 - Lograr una **puntuación de pronóstico asimétrica** (similar a la definida en el paper de la NASA) que penalice más las predicciones tardías que las tempranas.
- **KPI de Sistema (Rendimiento):**
 - El pipeline de inferencia debe ser capaz de procesar los datos de un nuevo ciclo de vuelo y devolver una predicción de RUL en **menos de 5 minutos**.
- **KPI de Adopción (Usabilidad):**
 - El dashboard debe ser considerado **"comprensible y accionable"** en una encuesta simulada a un usuario final (ej. un compañero de otro grupo actuando como ingeniero de mantenimiento o el propio profesor).